

大语言模型系统的知识治理

从 LLM 平庸，经由局部对齐，走向 LLM 卓越 – 短版图解

<https://wxy2ab.github.io/against-llm-mediocrity/zh/>

一句话：LLM 的关键问题不只是“会不会生成”，而是它观察、表征、指定、支持与聚合的东西，是否和真实任务价值对齐。

核心地图：从平庸到卓越

不是否定自回归，而是判断概率路径与任务价值是否同向。



干预原则 保留已对齐的部分，把高失配任务改造成更低失配、更接近卓越的子任务。

三个保留点

- LLM 平庸不是模型的普遍属性，而是任务、表征、状态、规格和预算共同形成的运行区间。
- 局部对齐是常态：模型能生成有价值部件，但全局目标仍可能漂移。
- 知识治理的目的，是把可验证、可撤销、可复用的控制知识从上下文叙事中外化出来。

1. 六类原始失配

六类原始失配：为什么搜索会停在“还不错”

它们不是表面症状，而是可达生成与真实任务价值分岔的诊断轴。

聚合失配
局部合理的续写，无法组合成全局高价值结构。
治：建立结构大纲与全局审计。

支持失配
高价值结构处在低概率或低支持区域，概率无法区分洞见与噪声。
治：显式枚举稀有结构与反例。

状态失配
效用依赖当前观测通道下不可识别的潜在状态。
治：补观测、建状态表、设置升级规则。

规格失配
提示词、训练规范或评估器偏离真实任务标准。
治：先生成评分规约，再产出结果。

拟合边界失配
已学能力的触发边界与真实适用边界不一致。
治：路由条件、禁用条件、触发测试。

观测-表征失配
观测、编码、上下文或工具通道丢失了任务充分变量。
治：改变表征与控制空间。

读法 先定位主要失配，再选择对应的控制动作。很多失败现象只是这些原始失配在预算、表征和控制策略下的复合结果。


这六类失配的价值在于诊断。它们帮助系统判断：继续采样、批判、重排或润色是否仍然有效，还是已经需要改变观测、表征、任务规格或控制结构。

派生失败模式，例如顺序敏感轨迹、语料先验主导、预算下的控制容量崩塌，通常不是新的原始类别，而是六类失配叠加预算与控制策略后的表现。

2. 从平庸到卓越的转化

从平庸到卓越：把任务换一种呈现方式

关键不是让模型停止生成，而是把困难目标拆成更容易正向对齐的中间任务。



可复用操作模式



落地句式 不要直接问“给我最佳答案”。先问“需要哪些状态、标准、约束和反例，才能判定答案是高价值的？”

转化的实质，是把一个高失配的最终输出问题，改写成多个更接近 LLM 卓越区间的子任务。例如先压缩上下文、提取变量、生成评分规约、枚举边界情形，再让模型写最终答案。

判断标准：如果子任务本身更容易被模型稳定完成，并且能为后续生成提供可检查的控制条件，那么转化就是有价值的。

3. 知识治理与 GKO

知识治理：把控制知识从上下文叙事中拿出来
最终表述与知识获取、验证、控制解耦，减少“看似合理”的漂移。



知识治理不是把所有过程都写进提示词，而是创建一个被承认的控制层。候选知识先被验证，再以 GKO 形式记录条件、证据、强度、优先级、生命周期与撤销规则。

对长程 agent 而言，SGAR 的重点是状态权威：计划、行动、观测、验证、升级、审计发现与撤销，不再只依赖上下文叙事，而成为可检查的状态转移。

4. 何时用，如何落地

何时需要知识治理：一个快速判断

治理不是普适必要项。只有当局部生成优势不足以支配全局价值时，它才值得引入。



最小落地清单

- 先标注任务中的已对齐部分：哪些生成、压缩、转换或枚举可以直接交给模型。
- 再标注高失配部分：隐藏状态、低支持结构、规格模糊、全局聚合或表征损失。
- 为高失配部分生成控制工件：评分规约、状态表、反例集、边界条件、路由规则。
- 把验证后的控制工件写成 GKO，并设置何时启用、何时撤销。
- 最后让模型只在受治理的边界内生成流畅表达，并用同一组 GKO 审计结果。

反面边界：如果任务本身已经处在 LLM 卓越区间，例如纯上下文压缩、语体迁移、结构化转换，普通提示或有限搜索可能更高效。